

# Tarefa - Introdução

Agosto 2025

**Disciplina: Redes Complexas**

**Professor: Vander L. S. Freitas**

**Aluno: Gabriel F. Costa**

**E-mail: gabriel.fc@aluno.ufop.edu.br**

## Tarefa

Encontre ao menos **um tipo de rede** relacionada ao seu trabalho na Pós-Graduação e responda aos seguintes pontos:

1. Descreva quais são seus **nós** e **links**.
2. Explique como ela se relaciona com a sua pesquisa.
3. Aponte o que seria interessante **investigar ou descobrir** sobre ela.
4. Verifique se há algo **semelhante na literatura**.

## Resolução

Dois tipos de redes relacionadas ao meu trabalho na Pós-Graduação são redes epidemiológicas temporais, representadas nos datasets **Chickenpox Hungary** e **England COVID-19** do *PyTorch Geometric Temporal*.

1. **Nós e links:**
  - **Chickenpox Hungary Dataset:**
    - **Nós:** os condados da Hungria.
    - **Links:** conexões de vizinhança geográfica entre condados.
    - **Features dos nós:** contagens semanais de casos de catapora com defasagens temporais (*lags*).
    - O grafo é **estático**, mas as features são temporais (*temporal signal*).

- **England COVID Dataset:**

- **Nós:** regiões NUTS3 da Inglaterra.
- **Links:** fluxos diários de pessoas entre regiões, baseado em dados de mobilidade do Facebook.
- **Features dos nós:** número de casos reportados nos últimos dias (*lags*).
- O grafo é **dinâmico**, dirigido e ponderado, variando a cada dia (*temporal signal*).

2. **Relação com a pesquisa:** Esses datasets dialogam diretamente com minha pesquisa, pois representam os dois cenários centrais que estudo: **grafos estáticos com sinais temporais** (caso da catapora na Hungria) e **grafos dinâmicos com evolução estrutural** (caso da COVID-19 na Inglaterra). Ambos permitem avaliar como diferentes arquiteturas de GNNs integram dependências espaciais e temporais, possibilitando comparar módulos recorrentes, convolucionais e baseados em atenção na tarefa de previsão de séries temporais em grafos.

3. **O que investigar ou descobrir:**

Primeiro, em relação à **rede** em si:

- Caracterizar propriedades estruturais dos grafos, como distribuição de graus, conectividade, componentes, presença de nós críticos e possíveis comunidades.
- Identificar regiões ou condados mais centrais na propagação, atuando como potenciais super-dispersores ou hubs de mobilidade.
- Analisar como padrões espaciais (vizinhança, fluxos) interagem com os sinais temporais na dinâmica de disseminação da doença.

Em seguida, em relação à **modelagem preditiva:**

- Avaliar se mecanismos de atenção (inspirados em Transformers) capturam melhor dependências temporais de longo alcance em comparação a módulos recorrentes ou convolucionais.
- Investigar como embeddings espaço-temporais aprendidos conjuntamente afetam a capacidade de generalização do modelo.
- Analisar o impacto da dinâmica do grafo na performance das arquiteturas, comparando previsões em cenários estáticos e dinâmicos.

4. **Semelhança na literatura:**

- O dataset de **Chickenpox Hungary** é usado como benchmark em *spatiotemporal graph neural networks* para prever séries temporais de doenças infecciosas.
- O dataset **England COVID** foi utilizado para estudar previsões de pandemia com base em mobilidade, conforme o artigo *Transfer Graph Neural Networks for Pandemic Forecasting*.
- Na literatura, há estudos sobre previsão em tráfego (DCRNN, STGCN, Graph WaveNet) e epidemiologia (COVID-19 China Mobility, Baidu Mo-

bility Data), todos reforçando a relevância de avaliar arquiteturas sob diferentes cenários de grafos estáticos e dinâmicos.